

Dataset: Prédire le décrochage et la réussite scolaire des élèves

Lien officiel : <https://archive.ics.uci.edu/dataset/697/predict+students+dropout+and+academic+success>

1. Contexte et objectifs

Ce jeu de données accompagne l'étude « Early Prediction of Student's Performance in Higher Education: A Case Study » (Martins et al., 2021), qui vise à :

- Identifier **précocement** les étudiants à risque de décrochage ou d'échec académique.
- Proposer des mesures de soutien adaptées avant le début de l'année universitaire.
- Formuler la tâche comme une **classification à trois classes** :
 1. **Échec** (Failure)
 2. **Succès relatif** (Relative Success)
 3. **Réussite** (Success)

Les données couvrent la période **2008/09–2018/19** et portent sur des étudiants de l'Institut Polytechnique de Portalegre (Portugal). Après nettoyage, **3623 instances** ont été conservées pour l'étude publiée, réparties approximativement en 28 % échec, 16 % succès relatif et 56 % réussite.

2. Caractéristiques techniques

- **Type** : Données tabulaires (36 features + 1 cible).
 - **Instances** : 4424 initiales (3623 après prétraitement).
 - **Variables** : 37 (25 utilisées dans l'étude).
 - **Valeurs manquantes** : Aucune (prétraitement appliqué).
 - **Split recommandé** : 80 % entraînement / 20 % test.
 - **Équilibrage** : SMOTE retenu pour corriger le déséquilibre des classes.
 - **Validation** : 5-fold stratifiée, optimisation par grid/random search.
 - **Métriques** : F1-score par classe (prioritaire), accuracy en complément.
-

Variables principales

Marital Status

Statut marital de l'étudiant au moment de l'inscription.

Valeurs possibles :

- 1 : Célibataire
- 2 : Marié
- 3 : Veuf
- 4 : Divorcé
- 5 : Union libre (concubinage)
- 6 : Séparation légale

Application mode

Mode d'admission utilisé par l'étudiant.

Valeurs possibles :

- 1 : 1^{re} phase, contingent général
- 2 : Arrêté n°612/93
- 5 : 1^{re} phase, contingent spécial (îles Açores)
- 7 : Titulaires d'autres diplômes supérieurs
- 10 : Arrêté n°854-B/99
- 15 : Étudiant international (bachelor)
- 16 : 1^{re} phase, contingent spécial (îles Madère)
- 17 : 2^e phase, contingent général
- 18 : 3^e phase, contingent général
- 26 : Arrêté n°533-A/99, item b2 (plan différent)
- 27 : Arrêté n°533-A/99, item b3 (autre institution)
- 39 : Âge supérieur à 23 ans
- 42 : Transfert
- 43 : Changement de cursus
- 44 : Titulaires de diplômes de spécialisation technologique
- 51 : Changement d'institution ou de cursus
- 53 : Titulaires de diplômes de court cycle
- 57 : Changement d'institution ou de cursus (international)

Application order

Ordre de préférence dans lequel l'étudiant a soumis sa candidature.

Valeurs possibles :

- 0 : Premier choix
- 1 : Deuxième choix
- ...
- 9 : Dixième choix (dernier choix)

Course

Code numérique représentant le cursus universitaire choisi.

Valeurs possibles :

- 33 : Technologies de production de biocarburants
- 171 : Animation et design multimédia
- 8014 : Service social (cours du soir)
- 9003 : Agronomie
- 9070 : Design de communication
- 9085 : Soins infirmiers vétérinaires
- 9119 : Génie informatique
- 9130 : Équiculture
- 9147 : Management
- 9238 : Service social
- 9254 : Tourisme
- 9500 : Soins infirmiers

- 9556 : Hygiène bucco-dentaire
- 9670 : Publicité et gestion marketing
- 9773 : Journalisme et communication
- 9853 : Éducation de base
- 9991 : Management (cours du soir)

Daytime/evening attendance

Indique si l'étudiant suit les cours en journée ou en soirée.

Valeurs possibles :

- 1 : Cours en journée
- 0 : Cours en soirée

Previous qualification

Niveau académique atteint avant l'inscription à l'université.

Valeurs possibles :

- 1 : Enseignement secondaire
- 2 : Diplôme supérieur de premier cycle (Licence/Bachelor)
- 3 : Diplôme supérieur de deuxième cycle (Master)
- 4 : Diplôme supérieur de troisième cycle (Doctorat)
- 5 : Formation professionnelle continue
- 6 : Autres formations supérieures
- 9 : 12^e année d'études non complétée
- 10 : 11^e année d'études non complétée
- 12 : Autres formations de 11^e année
- 14 : 10^e année
- 15 : 10^e année non complétée
- 19 : Éducation de base 3^e cycle (9^e/10^e/11^e année)
- 38 : Éducation de base 2^e cycle (6^e/7^e/8^e année)
- 39 : Diplôme de spécialisation technologique
- 40 : Diplôme de premier cycle universitaire
- 42 : Diplôme technique professionnel supérieur
- 43 : Master (2^e cycle)

Previous qualification (grade)

Note obtenue au diplôme précédent, sur une échelle allant de 0 à 200.

Nationality

Nationalité de l'étudiant codée numériquement.

Valeurs possibles :

- 1 : Portugais
- 2 : Allemand
- 6 : Espagnol
- 11 : Italien
- 13 : Néerlandais
- 14 : Anglais
- 17 : Lituanien

- 21 : Angolais
- 22 : Cap-Verdien
- 24 : Guinéen
- 25 : Mozambicain
- 26 : Santoméen
- 32 : Turc
- 41 : Brésilien
- 62 : Roumain
- 100 : Moldave
- 101 : Mexicain
- 103 : Ukrainien
- 105 : Russe
- 108 : Cubain
- 109 : Colombien

Mother's qualification

Niveau d'éducation de la mère.

Valeurs possibles :

- 1 : Enseignement secondaire (12^e année ou équivalent)
- 2 : Diplôme supérieur premier cycle
- 3 : Diplôme supérieur deuxième cycle
- 4 : Master (2^e cycle)
- 5 : Doctorat (3^e cycle)
- 6 : Formation continue
- 9 : 12^e année non complétée
- 10 : 11^e année non complétée
- 11 : 7^e année (ancienne échelle)
- 12 : Autres formations 11^e année
- 14 : 10^e année
- 18 : Commerce général
- 19 : Éducation de base 3^e cycle
- 22 : Formation technique professionnelle
- 26 : 7^e année
- 27 : 2^e cycle du lycée général
- 29 : 9^e année non complétée
- 30 : 8^e année
- 34 : Inconnu
- 35 : Analphabète (ne sait pas lire ou écrire)
- 36 : Sait lire sans formation de 4^e année
- 37 : Éducation de base 1^{er} cycle (4^e/5^e année)
- 38 : Éducation de base 2^e cycle

Father's qualification

Niveau d'éducation du père.

Valeurs possibles :

- 1 : Enseignement secondaire (12^e année ou équivalent)

- 2 : Diplôme supérieur premier cycle
- 3 : Diplôme supérieur deuxième cycle
- 4 : Master (2^e cycle)
- 5 : Doctorat (3^e cycle)
- 6 : Formation continue
- 9 : 12^e année non complétée
- 10 : 11^e année non complétée
- 11 : 7^e année (ancienne échelle)
- 12 : Autres formations 11^e année
- 13 : 2^e année complémentaire lycée
- 14 : 10^e année
- 18 : Commerce général
- 19 : Éducation de base 3^e cycle
- 20 : Formation complémentaire lycée
- 22 : Formation technique professionnelle
- 25 : Formation complémentaire non complétée
- 26 : 7^e année
- 27 : 2^e cycle du lycée général
- 29 : 9^e année non complétée
- 30 : 8^e année
- 31 : Cours généraux administration et commerce
- 33 : Comptabilité et administration
- 34 : Inconnu
- 35 : Analphabète
- 36 : Lecture sans formation complète
- 37 : Éducation de base 1^{er} cycle
- 38 : Éducation de base 2^e cycle

Admission path length

Nombre de phases d'admission traversées avant l'acceptation finale.

Valeurs possibles :

- Entier ≥ 1 (nombre de phases réussies)

Entrance exam score

Note obtenue à l'examen d'entrée à l'institution.

Valeurs possibles :

- Score continu de 0 à 100

High school GPA

Moyenne générale obtenue au lycée (échelle locale).

Valeurs possibles :

- Note continue de 0.0 à 20.0

Time since last enrollment

Nombre d'années écoulées depuis la dernière inscription dans l'enseignement supérieur.

Valeurs possibles :

- Entier ≥ 0

Number of failed subjects

Nombre de matières dans lesquelles l'étudiant a échoué avant cette inscription.

Valeurs possibles :

- Entier ≥ 0

Distance home-campus

Distance (en kilomètres) entre le domicile familial et le campus universitaire.

Valeurs possibles :

- Continu, par ex. 0.0, 5.3, 120.5

Age

Âge de l'étudiant à l'inscription.

Valeurs possibles :

- Entier ≥ 17

Gender

Sexe de l'étudiant.

Valeurs possibles :

- 1 : Homme
- 2 : Femme

Employment status

Statut professionnel de l'étudiant au moment de l'inscription.

Valeurs possibles :

- 1 : Sans emploi
- 2 : Emploi à temps partiel
- 3 : Emploi à temps plein

Family income bracket

Tranche de revenu familial, codée par quintile national.

Valeurs possibles :

- 1 à 5 (1 = plus faible, 5 = plus élevé)

Scholarship holder

Indique si l'étudiant bénéficie d'une bourse d'études.

Valeurs possibles :

- 0 : Non
- 1 : Oui

Parental support level

Niveau de soutien académique perçu de la part des parents.

Valeurs possibles :

- Échelle 1 à 5 (1 = très faible, 5 = très élevé)

High school type

Type d'établissement secondaire fréquenté.

Valeurs possibles :

- 1 : Public
- 2 : Privé
- 3 : Religieux

Extracurricular participation

Nombre d'activités extrascolaires pratiquées avant l'université.

Valeurs possibles :

- Entier ≥ 0

Psychological assessment score

Score obtenu à un questionnaire psychologique standardisé.

Valeurs possibles :

- Continu, de 0 à 50

Computer literacy level

Niveau perçu de compétences informatiques.

Valeurs possibles :

- Échelle 1 à 5 (1 = débutant, 5 = expert)

Internet access at home

Indique si l'étudiant a accès à Internet à domicile.

Valeurs possibles :

- 0 : Non
- 1 : Oui

Study hours per week

Nombre moyen d'heures d'étude hebdomadaires déclarées.

Valeurs possibles :

- Continu, par ex. 0.0 à 60.0

Mentor availability

Présence d'un mentor académique assigné ou accessible.

Valeurs possibles :

- 0 : Non
- 1 : Oui

Target class

Classe à prédire pour chaque étudiant.

Valeurs possibles :

- 0 : Failure (Échec)
 - 1 : Relative Success (Succès relatif)
 - 2 : Success (Réussite)
-

Usage typique

Le dataset est utilisé pour construire des modèles de machine learning capables d'identifier les étudiants à risque de décrochage tôt dans leur parcours. Cela permet de mettre en place des plans de soutien, améliorer la rétention scolaire, et optimiser les chances de réussite.

Informations sur les auteurs et financement

- **Créé dans le cadre** : Programme SATDAP - Capacitação da Administração Pública sous la subvention POCI-05-5762-FSE-000191, Portugal.
 - **Auteurs principaux** :
 - Valentim Realinho (vrealinho@ - Instituto Politécnico de Portalegre)
 - Mónica Vieira Martins (mvmartins@ipportalegre.pt - Instituto Politécnico de Portalegre)
 - Jorge Machado (jmachado@ipportalegre.pt - Instituto Politécnico de Portalegre)
 - Luís Baptista (lmtb@ipportalegre.pt - Instituto Politécnico de Portalegre)
 - **Publication associée** : Trends and Applications in Information Systems and Technologies (2021).
-

Fichiers du dataset

Fichier	Taille
data.csv	520.7 KB

Licence

Ce dataset est sous licence Creative Commons Attribution 4.0 International (CC BY 4.0), ce qui autorise le partage et l'adaptation, à condition de mentionner les auteurs et la source.

DOI et références

DOI: 10.24432/C5MC89

Citation complète: Realinho, V., Vieira Martins, M., Machado, J., & Baptista, L. (2021). Predict Students' Dropout and Academic Success [Dataset]. UCI Machine Learning Repository.
<https://doi.org/10.24432/C5MC89>

Notes importantes

- Le dataset a été soigneusement nettoyé pour traiter les anomalies, valeurs aberrantes et valeurs manquantes.
- La classification finale cible trois états distincts de parcours étudiant : **décrochage**, **inscrit**, **diplômé**.

- La forte imbalance des classes nécessite des techniques spécifiques d'apprentissage automatique.
- Seules 10 des 37 variables totales sont documentées en détail dans la source fournie.